

NAWIGACJA ROBOTÓW HUMANOIDALNYCH

WYKŁAD 2

Lokalizacja, odometria i fuzja sensoryczna

dr inż. Mateusz Pomianek



Estymacja stanu

Filtry EKF/UKF

Fuzja sensoryczna

SLAM

Plan wykładu

Sekcja 1

Estymacja stanu: odometria humanoida, dryft, dead reckoning, układy transformacji

Sekcja 2

Filtry estymacyjne: komplementarny, EKF, UKF, cząsteczkowy, fuzja IMU+enkodery+wzrok

Sekcja 3

Lokalizacja globalna, SLAM, pose graph, domykanie pętli, dobór metody

Kody Python

Całkowanie IMU, odometria kroku, filtr komplementarny, EKF 2D, korekta z landmarkem


Plan tego wykładu obejmuje trzy główne bloki. Najpierw omówimy estymację stanu, odometrię humanoida, dryft, dead reckoning i układy transformacji. Następnie przejdziemy do filtrów estymacyjnych, takich jak filtr komplementarny, EKF, UKF i filtr cząsteczkowy, oraz do fuzji IMU, enkoderów i wzroku. Na końcu zajmiemy się lokalizacją globalną i SLAM-em, w tym pose graphem, domykaniem pętli i dobozem metody do zadania.

01

SEKCJA

Estymacja stanu robota

Odometria, dryft, dead reckoning i układy transformacji



Czym jest stan robota humanoidalnego?

Pozycja i orientacja

x, y, z [m] oraz kąty roll, pitch, yaw [rad] w przestrzeni 3D

Prędkości

liniowa v [m/s] i kątowa ω [rad/s]:
wejście do modelu predykcji

Konfiguracja stawów

Kąty $q(t)$ [rad]: kinematyka prosta, Jacobian, zakres ruchu nóg

Stan kontaktu stóp

Lewa/prawa stopa: podparta, czy w locie? Kluczowe dla odometrii

Środek masy (CoM)

Pozycja CoM w przestrzeni; związana z warunkiem stabilności ZMP

Niepewność estymacji

Macierz kowariancji P , czyli miary zaufania do szacowanego stanu

Stan robota humanoidalnego jest wielowymiarowy. Obejmuje pozycję i orientację w przestrzeni 3D, prędkości liniowe i kątowe, konfigurację stawów, stan kontaktu obu stóp, położenie środka masy oraz niepewność estymacji opisaną macierzą kowariancji. To bardzo ważne: w praktyce nie estymujemy tylko samej pozycji, ale cały pakiet zmiennych potrzebnych do stabilnego sterowania i wiarygodnego planowania.

Odometria humanoida vs odometria kołowa

Odometria kołowa (AGV)

- Zliczanie impulsów enkoderów napędowych
- Proste równania kinematyczne (v , ω)
- Dryf głównie z poślizgu i nierówności kół
- Przewidywalny, mały błąd na krótkich dystansach
- Dojrzałe algorytmy korekcji (AMCL, EKF)

Odometria humanoida

- Integracja kroków + IMU + kontakty stóp
- Stan kontaktu: stopa oparta = referencyjna
- Dryf ze śliskich podłóg, wibracji tułowia
- Niesymetria kroków i ugięcie struktury
- Wymagana fuzja z wizją lub LiDAR-em

Odometria humanoida jest trudniejsza niż odometria platformy kołowej. W robocie kołowym liczymy impulsy enkoderów i stosujemy proste równania kinematyczne. W humanoidzie musimy integrować kroki, IMU i kontakty stóp. Dryft wynika nie tylko z poślizgu, ale też z asymetrii kroków, wibracji tułowia i ugięć struktury. Dlatego odometria humanoida niemal zawsze wymaga korekcji zewnętrznej, na przykład przez wizję albo LiDAR.

Dryft i błędy estymacji

- **Kumulacja błędów:** każde całkowanie dodaje szum; po 100 krokach błąd pozycji może wynosić $>0,5\text{m}$
- **Poślizg stopy:** nagła zmiana kontaktu stopy powoduje skok w estymowanej pozycji bazowej
- **Błędy kalibracji:** nieprecyzyjne IMU (niezrównoważenie osi) lub enkodery (luz w przekładni)
- **Szum żyroskopu:** dryft yaw przy całkowaniu prędkości kątowej – typowo $0,1\text{--}1^\circ/\text{s}$
- **Opóźnienia transmisji:** przesunięcie fazowe między sensorami zakłóca fuzję
- **Model kinematyczny:** uproszczenia (sztywne ogniwa, brak ugięcia) powodują systematyczny błąd
- **Zmiana środowiska:** ruchome podłoże (dywan, rampa) nie jest uwzględnione w modelu

Główne źródła błędów estymacji to kumulacja szumu przy całkowaniu, poślizg stopy, błędy kalibracji, szum żyroskopu, opóźnienia transmisji i uproszczenia modelu kinematycznego. Dochodzi też wpływ środowiska, na przykład miękkiej nawierzchni albo rampy, których model nie uwzględnia. Wszystkie te zjawiska powodują, że błąd lokalizacji narasta z czasem i bez korekty zewnętrznej nie da się go zatrzymać.

Idea i ograniczenia Dead reckoning

Na czym polega

- Estymacja pozycji wyłącznie z modelu i pomiarów wewnętrznych (*IMU, enkodery*)
- Brak korekty z zewnętrznych punktów odniesienia
- Całkowanie prędkości: $x(t) = x_0 + \int v(\tau) d\tau$
- Wystarczające w krótkim horyzoncie czasowym
- Zastosowanie: awaryjne przejście przez strefę bez GPS/LiDAR

Dlaczego nie wystarczy

- Błąd rośnie z kwadratem czasu (*całkowanie szumu*)
- Bez korekty dryft yaw na poziomie kilku stopni/min
- Po 30 s marszu błąd pozycji może przekroczyć 1m
- Nie wykrywa zakłóceń środowiskowych (*poślizg*)
- Konieczna fuzja z SLAM, GPS lub znacznikami

Dead reckoning to estymacja pozycji wyłącznie na podstawie modelu ruchu i pomiarów wewnętrznych, takich jak IMU i enkodery. W krótkim horyzoncie działa zaskakująco dobrze i bywa użyteczne jako rozwiązanie awaryjne. Problem polega na tym, że błąd rośnie wraz z czasem, szczególnie przez dryft orientacji. Po kilkudziesięciu sekundach marszu odchylenie pozycji może być już bardzo duże. Dlatego dead reckoning samo w sobie nie wystarcza i musi być wspierane przez zewnętrzne punkty odniesienia, SLAM albo znaczniki.

Referencyjne układy: map, odom, base

- **world** – absolutna ramka inercjalna; stała; punkt odniesienia misji
- **map** – ramka mapy SLAM; skokowe korekty przy domknięciu pętli; world $\approx$ map w małych środowiskach
- **odom** – ramka odometrii; ciągła, ale dryfuje; baza dla planisty lokalnego
- **base** – miednica / CoM robota; centrum drzewa kinematyki
- **Relacja kluczowa:** odom→map to korekta SLAM; base→odom to bieżąca odometria
- **ROS 2 tf2:** każda transformacja niesie timestamp; stare transformacje są buforowane
- **Niespójne drzewo TF** jest najczęstszą przyczyną błędów nawigacji w ROS-ie

W systemie lokalizacji kluczowe są trzy ramki: map, odom i base. Ramka map jest związana z mapą SLAM i może być korygowana skokowo przy domknięciu pętli. Ramka odom jest ciągła, ale dryfuje. Ramka base opisuje aktualne położenie bazy robota. Relacja odom→map to korekta globalna, a relacja base→odom to bieżąca odometria. W ROS-ie każda transformacja ma znacznik czasu i jest buforowana. Niespójne drzewo TF to jeden z najczęstszych praktycznych powodów awarii lokalizacji.

Kontakt stopy jako źródło informacji

- **Faza podparcia:** stopa oparta na podłożu (może służyć jako punkt odniesienia odometrii)
- **Faza przenoszenia:** stopa w locie (brak danych pozycyjnych z tej nogi)
- **Czujniki F/T w stopie mierzą 6-DoF:** $F_x, F_y, F_z, M_x, M_y, M_z$
- **Detekcja kontaktu:** $F_z > \text{próg}$ (np. 30 N) $\rightarrow$ stopa oparta; przydatne przy miękkich nawierzchniach
- **Kinematyczna odometria kroków:** pozycja bazy = pozycja stopy + FK^{-1}
- **Brak kontaktu obu stóp jednocześnie:** skok lub upadek – należy zresetować estymator
- **Fuzja z IMU:** stopa jako warunek brzegowy do korekcji dryftu yaw i translacji

Kontakt stopy jest bardzo cennym źródłem informacji. Gdy stopa jest w fazie podparcia, może pełnić funkcję punktu odniesienia dla odometrii. Gdy jest w fazie przenoszenia, tej informacji nie mamy. Czujniki sił i momentów w stopach pozwalają wykryć kontakt przez próg siły pionowej. Na tej podstawie możemy budować kinematyczną odometrię kroków i korygować estymację bazy. W połączeniu z IMU daje to istotne ograniczenie dryftu translacji i orientacji.

Metryki jakości lokalizacji

RMSE pozycji

Pierwiastek średniokwadratowego błędu xy [m] względem ścieżki referencyjnej

Błąd orientacji

Średni błąd kąta yaw [°];
krytyczny dla planowania kroków

Dryft na minutę

Narastanie błędu pozycji bez korekty zewnętrznej [m/min]

Spójność estymatora

Czy kowariancja P odpowiada rzeczywistemu błędowi? (test NIS/NEES)

Jakość lokalizacji oceniamy przez RMSE pozycji, błąd orientacji, dryft na minutę oraz spójność estymatora. Ta ostatnia cecha jest bardzo ważna, bo nie wystarczy mieć mały błąd. Estymator musi też poprawnie oceniać własną niepewność, a to sprawdzamy testami takimi jak NIS czy NEES.

Całkowanie prędkości kątowej z IMU

```
import numpy as np

class ImuIntegrator:
    def __init__(self):
        self.yaw = 0.0 # [rad]
        self.pitch = 0.0 # [rad]
        self.roll = 0.0 # [rad]

    def update(self, gyro_xyz: np.ndarray, dt: float) -> tuple:
        """Aktualizacja orientacji przez całkowanie żyroskopu"""
        # gyro_xyz = [omega_x, omega_y, omega_z] w rad/s
        self.roll += gyro_xyz[0] * dt
        self.pitch += gyro_xyz[1] * dt
        self.yaw += gyro_xyz[2] * dt
        return self.roll, self.pitch, self.yaw

# Przykład użycia:
integrator = ImuIntegrator()
roll, pitch, yaw = integrator.update(np.array([0.01, -0.02, 0.15]), dt=0.005)
```

Opis: Proste całkowanie żyroskopu → szybkie, lecz podatne na dryft bez korekty zewnętrznej

Odometria kroku i aktualizacja pozycji robota

```
import numpy as np

class StepOdometry:
    def __init__(self):
        self.x = 0.0 # [m]
        self.y = 0.0 # [m]
        self.yaw = 0.0 # [rad]

    def step(self, stride_len: float, delta_yaw: float) -> tuple:
        """Aktualizacja pozycji po jednym kroku (stride)."""
        self.yaw += delta_yaw
        self.x += stride_len * np.cos(self.yaw)
        self.y += stride_len * np.sin(self.yaw)
        return self.x, self.y, self.yaw

odo = StepOdometry()
for _ in range(10):
    x, y, yaw = odo.step(stride_len=0.35, delta_yaw=0.02)
```

Opis: Każdy krok aktualizuje pozycję bazy przez kinematykę planarną; **delta_yaw** pochodzi z IMU

02

SEKCJA

Filtry estymacyjne i fuzja sensoryczna

*EKF, UKF, filtr cząsteczkowy, fuzja
IMU+enkodery+wzrok*



Po co łączyć sensory?

Komplementarność

Żyroskop: szybki, dryfuje. Akcelerometr: wolny, stabilny kąt. Razem: lepiej.

Redundancja

Awaria jednego sensora nie blokuje estymacji, jeśli mamy zapas informacji.

Wzajemna korekta

Kamera koryguje skumulowany dryft IMU; IMU stabilizuje estymację przy rozmazaniu

Pewność statystyczna

Kowariancja złożona < kowariancja pojedynczego sensora (*reguła filtracji*)

Sensory łączy z czterech głównych powodów. Po pierwsze komplementarność, bo jeden sensor jest szybki, a drugi stabilny. Po drugie redundancja, bo awaria pojedynczego źródła nie powinna zatrzymać całej lokalizacji. Po trzecie wzajemna korekta, na przykład kamera koryguje dryft IMU, a IMU stabilizuje estymację obrazu. Po czwarte pewność statystyczna, bo połączona estymata może mieć mniejszą niepewność niż każdy sensor osobno.

Filtr komplementarny - intuicja

- **Idea:** połącz żyroskop (szybki, dryfuje) z akcelerometrem (wolny, stabilny w długim czasie)
- **Wzór:** $\theta(t) = \alpha \cdot (\theta_{\text{prev}} + \omega_{\text{gyro}} \cdot dt) + (1-\alpha) \cdot \theta_{\text{accel}}$
- **Parametr α :** blisko 1 (np. 0,98) – większe zaufanie do żyroskopu na krótkich interwałach
- **Działanie:** żyroskop śledzi szybkie zmiany; akcelerometr koryguje powolny dryft
- **Zalety:** niska złożoność obliczeniowa, brak macierzy – działa na mikrokontrolerze IMU
- **Wada:** nie uwzględnia niepewności pomiarowych (brak kowariancji) ani dynamiki zewnętrznej
- **Zastosowanie:** pochylenie tułowia robota w czasie rzeczywistym (roll i pitch)

Filtr komplementarny jest intuicyjny i bardzo użyteczny. Łączy szybki, ale dryfujący żyroskop z wolniejszym, lecz stabilnym akcelerometrem. Parametr alfa ustala proporcję zaufania do obu źródeł. Dzięki temu żyroskop śledzi szybkie zmiany, a akcelerometr powoli koryguje dryft. Zaletą jest prostota i mały koszt obliczeniowy. Wadą jest brak jawnej obsługi kowariancji i ograniczona możliwość modelowania pełnej dynamiki układu.

Filtr komplementarny dla kąta pochylenia

```
import numpy as np

class ComplementaryFilter:
    def __init__(self, alpha: float = 0.98):
        self.alpha = alpha
        self.pitch = 0.0 # estymowany kąt pochylenia [rad]

    def update(self, gyro_y: float, accel_xz: np.ndarray, dt: float) -> float:
        """Estymacja pitch z gyro i akcelerometru."""
        # Predykcja z żyroskopu
        pitch_gyro = self.pitch + gyro_y * dt
        # Pomiar kąta z akcelerometru (g_x i g_z)
        pitch_accel = np.arctan2(accel_xz[0], accel_xz[1])
        # Fuzja
        self.pitch = self.alpha * pitch_gyro + (1 - self.alpha) * pitch_accel
        return self.pitch
```

Opis: $\alpha \approx 0,98$: 98% z żyroskopu (szybkość) i 2% z akcelerometru (długoterminowa stabilność)

Porównanie filtrów: EKF, UKF, cząsteczkowy

EKF - Extended Kalman Filter

- **Linearyzacja Jacobianem** wokół aktualnego stanu
- **Niski koszt $O(n^2)$** : działa w czasie rzeczywistym
- Zakłada **Gaussowski rozkład szumu**
- **Zawodzi** przy silnej **nieliniowości modelu**
- **Złoty standard w robotyce mobilnej**

UKF - Unscented Kalman Filter

- **Sigma-points** zamiast **linearyzacji**
- **Lepsza** aproksymacja **nieliniowości**
- **Bez** konieczności wyliczania **Jacobiana**
- **Większy koszt** niż EKF ($2n+1$ punktów)
- **Zalecany** przy mocno **nieliniowych dynamikach**

Filtr cząsteczkowy (PF)

- **Wielomodalny** rozkład prawdopodobieństwa
- **N cząsteczek** jako hipotezy stanu
- **Resampling**: eliminacja słabych hipotez
- **Koszt $O(N)$** : wymaga wielu cząsteczek
- **Idealny** do lokalizacji globalnej (AMCL)

Jeżeli porównamy EKF, UKF i filtr cząsteczkowy, to każdy z nich ma inny profil zastosowań. EKF jest szybki i od lat stanowi standard w robotyce mobilnej, ale opiera się na linearyzacji. UKF lepiej radzi sobie z nieliniowością, bo używa punktów sigma zamiast Jacobianów, lecz jest droższy obliczeniowo. Filtr cząsteczkowy reprezentuje rozkład przez wiele hipotez stanu i świetnie nadaje się do lokalizacji globalnej, jednak wymaga znacznie większych zasobów. Wybór filtru zawsze jest kompromisem między kosztem a jakością modelowania.

Filtr Kalmana: cykl predykcja-korekcja

1

Predykcja

Model ruchu propaguje stan $\hat{x}$ i kowariancję P do przodu w czasie.

$$\hat{x}^- = F \cdot \hat{x} + B \cdot u$$

2

Pomiar

Sensor dostarcza nową obserwację z – zawierającą szum R .
Innowacja: $v = z - H \cdot \hat{x}^-$

3

Wzmocnienie K

Wagi Kalmana wyznaczają optymalny kompromis między modelem, a pomiarem.
 $K = P^- \cdot H^T \cdot (H \cdot P^- \cdot H^T + R)^{-1}$

4

Korekcja

Stan i kowariancja zaktualizowane o innowację.

$$\hat{x} = \hat{x}^- + K \cdot v$$
$$P = (I - K \cdot H) \cdot P^-$$

Filtr Kalmana pracuje w cyklu predykcja–korekcja. Najpierw model ruchu propaguje stan i kowariancję w przyszłość. Następnie przychodzi nowy pomiar obarczony szumem. Z różnicy między pomiarem a przewidywaniem powstaje innowacja. Potem liczymy wzmocnienie Kalmana, które określa, jak bardzo zaufać modelowi, a jak bardzo sensorowi. Na końcu aktualizujemy stan i kowariancję. To jest centralny mechanizm nowoczesnej fuzji sensorycznej.

Uproszczony EKF dla pozycji 2D

```
import numpy as np

class EKF2D:
    def __init__(self):
        self.x = np.zeros(3)          # [x, y, yaw]
        self.P = np.eye(3) * 0.5      # kowariancja początkowa
        self.Q = np.diag([0.01, 0.01, 0.005]) # szum procesu
        self.R = np.diag([0.1, 0.1])  # szum pomiaru (x, y)

    def predict(self, v: float, omega: float, dt: float):
        yaw = self.x[2]
        self.x += np.array([v*np.cos(yaw)*dt, v*np.sin(yaw)*dt, omega*dt])
        F = np.eye(3); F[0,2]=-v*np.sin(yaw)*dt; F[1,2]=v*np.cos(yaw)*dt
        self.P = F @ self.P @ F.T + self.Q

    def correct(self, z_xy: np.ndarray):
        H = np.array([[1,0,0],[0,1,0]])
        S = H @ self.P @ H.T + self.R
        K = self.P @ H.T @ np.linalg.inv(S)
        self.x += K @ (z_xy - self.x[:2])
        self.P = (np.eye(3) - K @ H) @ self.P
```

Opis: predict() używa modelu jednośladowego (unicycle); correct() koryguje pomiar GPS lub znacznika

Fuzja IMU, enkoderów i wizji

- **IMU (200 Hz):** predykcja stanu – szybka propagacja orientacji i przyspieszenia
- **Enkodery + kontakty stóp (100–500 Hz):** kinematyczna odometria kroków – korekta translacji
- **Kamera (30 Hz) / LiDAR (10 Hz):** obserwacje pozycyjne – usuwanie skumulowanego dryfu
- **Architektura loosely coupled:** każde źródło dostarcza niezależnej estymatę pozycji do EKF
- **Architektura tightly coupled:** surowe pomiary sensorów trafiają bezpośrednio do jednego filtru
- **Opóźnienia:** pomiar z kamery z 33 ms opóźnieniem wymaga cofnięcia stanu (state rewinding)
- **Stan złożony:** $x = [\text{pos}, \text{vel}, \text{orient}, \text{biasy IMU}]$ – typowo 15–21 zmiennych stanu

W pełnym systemie humanoida typowa architektura wygląda tak: IMU pracuje bardzo szybko i służy do predykcji stanu, enkodery wraz z kontaktami stóp korygują translację przez odometrię kroków, a kamera albo LiDAR dostarczają rzadszych, ale absolutnie kluczowych obserwacji pozycyjnych, które kasują skumulowany dryft. Można to spiąć architekturą loosely coupled, gdzie źródła dają osobne estymaty, albo tightly coupled, gdzie do jednego filtru trafiają surowe pomiary. Przy tym trzeba jeszcze uwzględnić opóźnienia i biasy IMU.

Wykrywanie awarii sensora

Test innowacji (chi-squared)

- Innowacja $v = z - H \cdot \hat{x}^-$ powinna być zbliżona do zera
- Statystyka χ^2 : $v^{-1} \cdot S^{-1} \cdot v > \text{próg} \rightarrow \text{sensor awaryjny}$
- Zaimplementowane w bibliotekach iSAM2, GTSAM
- Działa online, bez zatrzymywania robota

Tryb degradacji (graceful degradation)

- Awaria kamery $\rightarrow$ nawigacja tylko na IMU + enkodery
- Awaria LiDAR $\rightarrow$ zmniejszony zasięg planowania
- Awaria jednej stopy F/T $\rightarrow$ wyłącz kinematyczną odo dla tej nogi
- Zwiększenie macierzy Q i P $\rightarrow$ większy obszar niepewności

Dobry system lokalizacji musi również wykrywać awarie sensorów. Robi się to między innymi przez analizę innowacji. Jeśli różnica między pomiarem a przewidywaniem staje się statystycznie zbyt duża, uznajemy sensor za niewiarygodny. Wtedy system przechodzi w tryb degradacji, na przykład jedzie bez kamery albo wyłącza odometrię jednej stopy. Jednocześnie rośnie niepewność estymacji, co powinno znaleźć odbicie w macierzach Q i P.

03

SEKCJA

Lokalizacja globalna i SLAM

ICP, visual odometry, pose graph, domykanie pętli



Lokalizacja względem znanych map

1. **Cel:** wyznaczenie pozycji robota w już zbudowanej mapie środowiska
2. **Monte Carlo Localization (*MCL / AMCL*):** filtr cząsteczkowy z obserwacjami LiDAR
3. **Matching 2D:** porównanie aktualnego skanu z mapą zajętości – scoring hipotez
4. **Matching 3D (*ICP*):** dopasowanie chmury punktów do globalnej mapy PCL
5. **Histogram Filter (*HMM*):** dyskretne komórki mapy jako hipotezy lokalizacji
6. **Warunek dobrej lokalizacji:** mapa aktualna i środowisko o charakterystycznych elementach
7. **Kidnapped robot problem:** wymagana inicjalizacja globalna, gdy pozycja startowa jest nieznana

Lokalizacja względem znanej mapy polega na znalezieniu pozycji robota w już istniejącym modelu środowiska. Można to robić filtrem cząsteczkowym AMCL z obserwacjami LiDAR, dopasowaniem skanu 2D do mapy zajętości, ICP dla chmur 3D albo filtrem histogramowym. Warunkiem sukcesu jest aktualna mapa i środowisko z wystarczająco charakterystycznymi elementami. Jeśli robot zostanie przeniesiony w nieznane miejsce, pojawia się problem kidnapped robot i wtedy potrzebna jest inicjalizacja globalna.

ICP – Iterative Closest Point

- **Cel:** znalezienie transformacji (R, t) minimalizującej odległości między dwoma chmurami punktów
- **Krok 1 – Korespondencja:** dla każdego punktu źródłowego znajdź najbliższy punkt w chmurze docelowej
- **Krok 2 – Estymacja:** oblicz optymalną transformację (metoda SVD lub minimalizacja MLS)
- **Krok 3 – Aktualizacja:** zastosuj transformację i oblicz błąd residualny
- **Iteruj do zbieżności** (błąd $<$ próg) lub **osiągnięcia max. iteracji**
- **Wady:** wolna zbieżność, wrażliwość na punkt startowy (koniecznie dobre wstępne wyrównanie)
- **Warianty:** Point-to-Plane ICP, GICP – znacznie szybsze i bardziej niezawodne

ICP, czyli Iterative Closest Point, służy do znajdowania transformacji między dwiema chmurami punktów. Najpierw wyznaczamy korespondencje, potem obliczamy transformację minimalizującą błąd, aktualizujemy położenie i iterujemy do zbieżności. Metoda jest bardzo ważna, ale ma też swoje ograniczenia: bywa wolna i jest czuła na punkt startowy. Dlatego w praktyce stosuje się też warianty takie jak point-to-plane ICP albo GICP.

Odometria wizyjna (Visual Odometry)

Monokularna VO

- Śledzenie cech ORB/SIFT między klatkami
- Essential Matrix → ruch kamery R, t
- Skala ruchu nieznana (do 5-punktowego)
- Skumulowany dryft bez domknięcia pętli
- Niska cena – jedna kamera wystarczy

Stereofoniczna / RGB-D VO

- Bezpośrednia metryczna skala ruchu
- Głębia z paralaksy lub strukturyzowanego światła
- Mniejszy dryft niż mono VO
- Wymagana synchronizacja i kalibracja stereo
- Podstawa Visual-Inertial Odometry (VIO)

Odometria wizyjna może być monokularna albo stereofoniczna, ewentualnie RGB-D. W wersji monokularnej śledzimy cechy między klatkami i odzyskujemy ruch kamery, ale tracimy metryczną skalę. W stereo albo RGB-D skala jest bezpośrednio dostępna, więc dryft jest zwykle mniejszy. To właśnie dlatego systemy visual-inertial odometry tak często opierają się na stereo lub głębi, szczególnie wtedy, gdy zależy nam na stabilnej estymacji metrycznej.

SLAM – Simultaneous Localization and Mapping

- **Problem sprzężony:** mapa zależy od dobrej lokalizacji; lokalizacja zależy od dobrej mapy
- **Online SLAM:** estymacja bieżącej pozycji i mapy w czasie rzeczywistym
- **Full SLAM:** pełna trajektoria i mapa (post-processing w np. Google Cartographer)
- **Dane obserwacyjne:** LiDAR (2D/3D SLAM), kamera (Visual SLAM – ORB-SLAM3, RTAB-Map)
- **Reprezentacja mapy:** chmura punktów, mapa cech (deskryptory), submapa siatek
- **Współdziałanie z planistą:** gotowa mapa przekazywana do globalnego planisty ścieżki
- **Błąd rośnie liniowo z odległością** bez domknięcia pętli; po 100 m może sięgnąć kilku metrów

SLAM to jednoczesna lokalizacja i mapowanie. Jest to problem sprzężony, bo dobra mapa wymaga dobrej lokalizacji, a dobra lokalizacja wymaga dobrej mapy. W wersji online system estymuje bieżącą pozycję i buduje mapę w czasie rzeczywistym. W wersji full SLAM optymalizujemy całą trajektorię i mapę również po zakończeniu przejazdu. Możemy robić to na danych z LiDAR-u albo kamery, a wynik trafia potem do planisty globalnego. Bez domknięcia pętli błąd rośnie wraz z odległością i może stać się bardzo duży.

Pose Graph SLAM, czyli idea grafowa SLAM-u

1

Węzły (*poses*)

Każda pozycja robota $x_1, x_2, \dots, x_n$ to wierzchołek w grafie; zazwyczaj SE(2) lub SE(3)

2

Krawędzie (*constraints*)

Relacja między dwoma pozycjami: odometria, ICP, wizja. Niesie kowariancję błędu.

3

Optymalizacja

Minimalizacja sumy błędów kwadratowych (least squares): g2o, GTSAM, iSAM2

4

Domknięcie pętli

Detekcja powrotu do miejsca; dodanie krawędzi pogrubionej; jednorazowa korekta dryfu

Pose Graph SLAM ujmuje problem w formie grafu. Węzły reprezentują kolejne pozycje robota, a krawędzie relacje między nimi: odometrię, dopasowanie ICP albo ograniczenia z wizji. Każda krawędź niesie też informację o niepewności. Optymalizacja grafu polega na minimalizacji sumy błędów wszystkich ograniczeń. Gdy wykryjemy powrót do wcześniej odwiedzonego miejsca, dodajemy nową krawędź i globalnie korygujemy cały przebieg trajektorii.

Domykanie pętli (*loop closure*)

Detekcja powrotu do miejsca

- **Bag-of-Words** (DBoW2): histogram deskryptorów wizualnych
- **Scan matching**: ICP między bieżącym, a historycznym skanem
- **Mapa cech**: dopasowanie deskryptorów ORB/SIFT
- **Próg podobieństwa**: zapobiega fałszywym detekcjom
- **Weryfikacja geometryczna**: RANSAC na korespondencjach

Korekta dryfu po domknięciu

- **Nowa krawędź** w pose graph z małą kowariancją
- **Optymalizator** (g2o) przelicza cały graf
- **Błąd dryfu** rozłożony wzdłuż zamkniętej pętli
- **Efekt**: mapa globalna spójna bez artefaktów
- **Częstość**: co kilka sekund dla środowisk cyklicznych

Domykanie pętli składa się z dwóch etapów. Najpierw trzeba wykryć, że wróciliśmy do znanego miejsca, na przykład przez bag of words, scan matching albo dopasowanie deskryptorów cech. Potem trzeba to jeszcze zweryfikować geometrycznie, często przez RANSAC. Jeśli wynik jest wiarygodny, dodajemy mocne ograniczenie do grafu i uruchamiamy optymalizację. Efekt jest taki, że skumulowany dryft rozkłada się po całej pętli, a mapa staje się globalnie spójna.

Prosta korekta pozycji po detekcji znacznika

```
import numpy as np

def correct_with_landmark(state: np.ndarray,
                          P: np.ndarray,
                          landmark_pos: np.ndarray,
                          measured_pos: np.ndarray,
                          R_meas: np.ndarray) -> tuple:
    """Korekta EKF po pomiarze pozycji znajomego znacznika."""
    H = np.eye(2, 3) # obserwujemy tylko x, y
    predicted_z = landmark_pos[:2]
    innovation = measured_pos - predicted_z
    S = H @ P @ H.T + R_meas
    K = P @ H.T @ np.linalg.inv(S) # wzmacnienie Kalmana
    state_new = state + K @ innovation
    P_new = (np.eye(3) - K @ H) @ P
    return state_new, P_new
```

Opis: Korekta EKF: innowacja z detekcji ArUco/AprilTag eliminuje skumulowany dryft odometrii

Dobór metody lokalizacji do zadania

Laboratorium

Znana, statyczna mapa; AMCL z LiDAR-em 2D wystarczy; opcjonalnie znaczniki ArUco

Biuro

Zmienna mapa (meble); SLAM online (Cartographer) + MCL; UWB jako wsparcie

Magazyn

Pojazdy AGV i regały; Visual SLAM z kamerami panoramicznymi; QR na półkach

Schody

3D LiDAR SLAM (LeGO-LOAM) lub RGB-D SLAM (RTAB-Map); height map aktywna

Dynamiczne otoczenie

EKF + filtr cząsteczkowy; odrzucanie ruchomych obiektów ze skanów mapowania

Zewnętrzne warunki

GPS + IMU (EKF) jako baza; LiDAR do refinement; odporność na warunki pogodowe

Dobór metody lokalizacji zależy od zadania. W laboratorium zwykle wystarcza AMCL z LiDAR-em 2D. W biurze, gdzie środowisko się zmienia, lepiej sprawdza się SLAM online z dodatkowym wsparciem. W magazynie przydaje się visual SLAM i znaczniki na regałach. Na schodach potrzebujemy już 3D LiDAR SLAM albo RGB-D SLAM wraz z aktywną height mapą. W dynamicznym otoczeniu trzeba odrzucać ruchome obiekty, a na zewnątrz połączyć GPS z IMU i LiDAR-em. Nie istnieje jedna uniwersalna metoda dobra do wszystkiego.

PODSUMOWANIE

- 01 **Dryft odometrii jest nieunikniony:** konieczna jest korekta z zewnętrznych sensorów lub SLAM
- 02 **Filtr Kalmana (EKF/UKF)** to złoty standard fuzji IMU, enkoderów i danych wizyjnych
- 03 **Filtr cząsteczkowy** radzi sobie z wielomodalnością, lecz wymaga większych zasobów obliczeniowych
- 04 **SLAM** (jednoczesne mapowanie i lokalizacja): pozwala robotowi budować i korygować mapę w locie
- 05 **Domykanie pętli** eliminuje skumulowany dryft; awarię sensora wykrywa się przez test innowacji

Pytania i mini-studium przypadku

1. Dlaczego filtr komplementarny nie może zastąpić EKF w pełnym systemie lokalizacji?
2. Jak wzmacnienie Kalmana K zmienia się, gdy macierz szumu pomiaru R jest bardzo duża?
3. Co to jest NIS (Normalized Innovation Squared) i jak wykrywa awarię sensora?
4. Opisz, jakie sensory i jakie filtry wybrać, dla humanoida patrolującego budynek przez 30 min, aby błąd pozycji nie przekroczył 0,3m. Jakie jest minimalne wymaganie na częstotliwość domknięcia pętli?

Zadanie

Zaimplementuj StepOdometry z Sekcji 1 i porównaj dryft z i bez korekty z EKF przy symulowanym szumie $yaw = 0,02$ rad/krok.