

NAWIGACJA ROBOTOW HUMANOIDALNYCH

WYKLAD 7

Nawigacja społeczna:

tlumy, normy kulturowe, interakcja z czlowiekiem

dr inż. Mateusz Pomianek



Modele tlumu

Proksemika

Normy kulturowe

HRI / personalizacja

Plan wykładu

Sekcja 1

Modele ruchu tłumu: Social Force Model, ORCA, modele oparte na danych, predykcja trajektorii

Sekcja 2

Proksemika i normy kulturowe: strefy Halla, różnice kultur, kontekst sytuacyjny, sygnały społeczne

Sekcja 3

Personalizacja interakcji człowiek-robot: profil użytkownika, uczenie preferencji, komunikacja, ewaluacja

Kody Python

Social Force Model, ORCA, predykcja Transformer, klasyfikator profilu, mapa społecznych kosztów

01

SEKCJA

Modele ruchu tłumu

Social Force Model, ORCA, modele predykcji trajektorii, detekcja grup



Dlaczego nawigacja społeczna jest potrzebna?

- Robot poruszający się tylko według geometrii ($A^* + DWA$) jest postrzegany jako nieprzewidywalny i nieprzyjemny
- **Badania (Kruse et al., 2013):** 70% użytkowników odczuwa dyskomfort, gdy robot nie respektuje nienawigacyjnych norm społecznych
- **Normy społeczne:** nie wchodzić między rozmawiające osoby, nie scigać pieszych, utrzymywać właściwy dystans
- **Nawigacja społeczna** rozszerza klasyczne planowanie o model agentów: każdy człowiek ma intencje, prędkość i strefę prywatności
- **Standard ISO 13482:2014:** roboty opiekuncze muszą spełniać minimalne wymagania dotyczące bezpiecznej interakcji z człowiekiem
- **Cel:** robot postrzegany jako naturalny uczestnik przestrzeni społecznej, a nie przeszkoda lub zagrożenie

Social Force Model (SFM) - Helbing i Molnar (1995)

- **Idea:** ruch pieszego modelowany jako suma sil: predkosc docelowa + odpychanie od przeszkod + odpychanie od innych ludzi
- **Sila własna:** $F_i^{\text{self}} = (v_i^0 * e_i^0 - v_i) / \tau_i$ (powrot do pozadanej predkosci i kierunku)
- **Sila społeczna** (odpychanie): $F_{ij} = A * \exp((r_{ij} - d_{ij})/B) * n_{ij}$ (im bliżej, tym silniej)
- **Sila od przeszkod:** analogiczna do społecznej; gradient prostopadly do powierzchni sciany
- **Wynikowa:** $m_i * (dv_i/dt) = F_i^{\text{self}} + \sum(F_{ij}) + \sum(F_{iW})$
- **Zalety:** prosta implementacja, przewidywalne zachowanie, dziala w czasie rzeczywistym (~1 ms / agent)
- **Wady:** kalibracja parametrow (A, B, tau) wymaga danych pomiarowych; nie modeluje intencji dlugookresowych

Social Force Model - implementacja dla planisty lokalnego



```
import numpy as np
```

```
def social_force(robot_pos, robot_vel, goal_pos, pedestrians,
                 A=2.0, B=0.3, tau=0.5, v0=1.2):
    """Wyznacza wypadkowa sile spoleczna dla robota."""
    e0 = goal_pos - robot_pos
    e0 /= (np.linalg.norm(e0) + 1e-6)          # kierunek do celu
    # Sila wlasna: robot chce isc do celu z predkoscia v0
    f_self = (v0 * e0 - robot_vel) / tau
    # Sily odpychajace od pieszych
    f_social = np.zeros(2)
    for ped in pedestrians:
        diff = robot_pos - ped['pos']          # wektor od pieszego do robota
        dist = np.linalg.norm(diff)
        r_ij = 0.3 + ped.get('radius', 0.25)   # suma promieni
        n_ij = diff / (dist + 1e-6)             # wektor normalny
        f_social += A * np.exp(-(r_ij - dist) / B) * n_ij
    return f_self + f_social                    # f_w / e^22
```

Opis: Wywolywac co 50 ms; scalkuj sile przez dt aby uzyskac nowa predkosc; clampuj do v_{max} .

ORCA - Optimal Reciprocal Collision Avoidance

Idea ORCA (van den Berg et al., 2011)

- Każdy agent przyjmuje połowę odpowiedzialności za uniknięcie kolizji
- **Dla każdej pary (I, J):** wyznaczana jest half-plane bezpiecznych prędkości
- **Nowa prędkość agenta I:** najbliższy punkt do prędkości preferencji w zbiorze bezpiecznych prędkości
- **Warunek:** przy wzajemnym stosowaniu ORCA przez wszystkich agentów brak kolizji jest gwarantowany
- **Złożoność:** $O(N)$ per agent per krok; praktyczne dla $n < 500$ agentów
- Popularny w symulatorach: CrowdSim, MENGE, PedSim

ORCA dla robota wpośród pieszych

- Robot zna swoją prędkość preferencji V_{PREF} (z DWA lub WMA)
- Dla każdego wykrytego pieszego wyznacza half-plane ORCA
- **Wynikowa prędkość:** projekcja V_{PREF} na przecięcie half-planes
- **Pieszy nie stosuje ORCA:** robot bierze pełną odpowiedzialność
- **Rozszerzenie:** RVO2 library (C++/Python); działa w czasie rzeczywistym
- **Ograniczenie:** nie przewiduje intencji; zakreśla ruch stały

Predykcja trajektorii pieszych

Modele kinematyczne

- **Stałość prędkości (CV):** $x_{t+1} = x_t + v \cdot dt$
- **Stałość przyspieszenia (CA):** uwzględnia inercję
- **Filtr Kalmana:** estymacja + predykcja
- Prosta, szybka, działa krótkoterminowo
- Zawodzi przy zmianie kierunku lub zatrzymaniu
- **Horyzont:** do ~ 1 s

Social Force / ORCA

- Model interakcji między agentami
- **Predykcja**, z uwzględnieniem dynamiki tłumu
- Wymaga pozycji wszystkich pieszych
- Średnio skuteczny na krótkim horyzoncie
- Może propagować błędy siły społecznej
- **Horyzont:** 1–3 s

Modele danych (DL)

- Social LSTM / Social GAN (Alahi 2016)
- Trajectron++ (Salzmann 2021)
- **Transformer:** AgentFormer, Wayformer
- Uwzględniają kontekst i interakcje
- Wymagają treningu na danych (UCY, ETH)
- **Horyzont:** 3–5 s; SoTA na benchmarkach

Detekcja grup i zachowan zbiorowych

- Ludzie czesto poruszaja sie w grupach (dyady, triady, rodziny); robot nie moze wejsc miedzy czonkow grupy
- **Detekcja grupy:** clustering pieszych wedlug wspolnej predkosci i bliskosci; DBSCAN lub hierarchical clustering
- **Formacja grupy:** trojkat, linia, V-ksztalt; kazda ma strefe chroniona miedzy czlonkami (O-space)
- **O-space (Kendon 1990):** przestrzeń miedzy członkami grupy; robot musi ją ominąć, nie przejść na wprost
- **F-formation detection:** detekcja wspolnej orientacji i pola widzenia; robot planuje objazd z zewnatrz
- **Zastosowanie:** robot chcacy podejsc do osoby czeka na rozejscie sie grupy lub sygnalizuje chec dolaczenia
- **Implementacja:** Social NavMesh uwzgledniajacy O-spaces jako dynamiczne przeszkody kosztowe w cost map

Spoleczna mapa kosztow i integracja z Nav2



```
import numpy as np

def build_social_costmap(grid_size, resolution, pedestrians,
                        sigma_pos=0.8, sigma_vel=0.5) -> np.ndarray:
    """Bduje mape kosztow uwzgledniajaca pieszych (Gaussowy potencjal)."""
    cost = np.zeros((grid_size, grid_size), dtype=np.float32)
    cx = cy = grid_size // 2 # srodek mapy = pozycja robota
    for p in pedestrians:
        px = int(cx + p['x'] / resolution)
        py = int(cy + p['y'] / resolution)
        vx, vy = p.get('vx', 0.0), p.get('vy', 0.0)
        for gy in range(grid_size):
            for gx in range(grid_size):
                dx, dy = gx - px, gy - py
                # Wydłużony Gauss w kierunku ruchu (anizotropowy)
                fwd = dx*vx + dy*vy + 1e-6 # składowa w przód
                d2 = dx**2/sigma_pos**2 + dy**2/sigma_pos**2
                d2 = max(fwd, 0)**2 / (sigma_vel**2)
```

Opis: Anizotropowy Gauss: większy koszt z przodu pieszego (w kierunku ruchu) niż z boku lub tyłu.

02

SEKCJA

Proksemika i normy kulturowe

*Strefy osobiste, różnice kulturowe, kontekst
sytuacyjny, sygnały społeczne*



Strefy proksemiczne E. Halla - przestrzen osobista czlowieka

Publiczna > 3,6 m

Spoleczna 1,2 – 3,6 m

Osobista 0,45 – 1,2 m

Intymna < 0,45 m



Implikacje dla robota

- Robot powinien utrzymywać dystans społeczny (1,2 m) przy podejściu do nieznanej osoby
- **Wejście w strefę osobistą** wymaga sygnału zaproszenia lub wyraźnej zgody użytkownika
- **Strefa intymna**: tylko w przypadku asystencji medycznej lub dostępu do dozownika leków
- **Nawigacja**: robot omija ludzi z marginesem 0,5 m = strefa bezpieczna powyżej osobistej
- **Monitoring**: czujnik F/T lub detekcja YOLO jako trigger zatrzymania przy nadmiernym zbliżeniu

Roznice kulturowe w przestrzeni osobistej

- **Kultury kontaktowe** (Ameryka Południowa, Bliski Wschód, Europa Południowa): dystans konwersacyjny 0,5–0,9 m
- **Kultury zdystansowane** (Europa Północna, Japonia, USA): dystans konwersacyjny 0,9–1,5 m
- **Kultury Azji Wschodniej**: wyjątkowo duży dystans w kontekście formalnym; mały dystans w zatłoczonej przestrzeni publicznej
- **Robot współpracujący globalnie** musi adaptować parametry stref do kontekstu kulturowego użytkownika
- **Dane badawcze**: Hall (1966), Beaulieu (2004), meta-analiza Sorokowska et al. (2017) na 42 krajach
- **Implementacja**: baza danych norm kulturowych + modul detekcji języka / regionu z konta użytkownika
- **Ostrożność**: stereotypizacja kulturowa jest ryzykowna; preferencje indywidualne mają priorytet nad normami grupowymi

Kontekst sytuacyjny a normy nawigacyjne

Srodowiska o wysokiej gestosc (public)

- **Dworce, lotniska, centra handlowe:** $\text{tłum} > 1 \text{ os/m}^2$
- **Akceptowalny kontakt fizyczny** (ramie w ramie), norma kulturowa
- **Robot:** tryb zwarty; wąska trasa, mniejszy dystans bezpieczny (0,4 m)
- **Predkosc zredukowana** do max 0,6 m/s; częste zatrzymania
- **Priorytet:** przepuszczanie grup idących w tym samym kierunku
- **Sygnalizacja:** oświetlenie LED i dźwięk przy zbliżaniu

Srodowiska opieki (szpital, dom opieki)

- **Pacjenci, osoby starsze, dzieci:** wzmocniona strefa bezpieczna (+50%)
- **Predkosc** max 0,4 m/s; płynne przyspieszenia i hamowania
- **Brak nagłych ruchow;** robot nie powinien pojawisc sie od tyłu
- **Zachowanie przewidywalne** i komunikowane z wyprzedzeniem
- **Pierwszenstwo** dla personelu medycznego niezależnie od ścieżki
- **Dźwięk sygnalizacyjny:** małe natężenie, przyjazny ton

Sygnały społeczne - co robot musi rozpoznawac

Gesty i mowa ciała

Wyciągnięta reka = stop; kiwniecie głową = zgoda;
odwrócenie się = koniec interakcji.

Detekcja: MediaPipe Pose

Kontakt wzrokowy

Wzrok skierowany na robota = oczekiwanie interakcji;
brak kontaktu = nie przeszkadzać.

Detekcja: gaze estimation

Mowa i prosodia

Komenda głosowa; ton i tempo sygnalizują stan emocjonalny. ASR + klasyfikator sentymentu w czasie rzeczywistym

Orientacja ciała

Zwrot frontem do robota = zaproszenie;
bok lub tył = brak zainteresowania.

Kluczowe dla decyzji o podejściu

Ekspresja twarzy

Dezorientacja, niezadowolenie, panika.

Detekcja: modele AU (Action Units)
lub end-to-end (AffectNet, FER2013)

Czynniki sytuacyjne

Osoba śmieciąca z tornistrem: zajęta.

Osoba stojąca i patrząca: czeka.

Kontekst wnioskowany z położenia i gestów

Kodowanie norm społecznych w mapie kosztów

- **Warstwa geometryczna:** klasyczne przeszkody statyczne (ściany, meble) z inflacją 0,3 m
- **Warstwa pieszych:** anizotropowy Gauss wokół każdej osoby; większy koszt w kierunku ruchu i z przodu twarzy
- **Warstwa grup:** O-space między członkami grupy kodowany jako strefa zakazana (koszt = 100)
- **Warstwa konwersacji:** obszar między rozmawiającymi osobami; robot nie może go przeciąć
- **Warstwa kulturowa:** globalny mnożnik kosztów ($\times 1.0 - \times 1.5$) zależnie od profilu kulturowego środowiska
- **Warstwa kontekstowa:** szpital: +30% kosztu wszędzie; ruchliwy korytarz biurowy: -10% kosztów bocznych
- **Aktualizacja:** wszystkie warstwy odświeżane co 100 ms na podstawie detekcji pieszych z LiDAR + kamery

03

SEKCJA

Personalizacja interakcji człowiek-robot (HRI)

*Profil użytkownika, uczenie preferencji, komunikacja,
ewaluacja*



Czym jest personalizacja w nawigacji społecznej?

Robot generyczny zachowuje się tak samo wobec każdego



Robot spersonalizowany adaptuje zachowanie do konkretnej osoby

Wymiary personalizacji: dystans fizyczny, styl komunikacji, prędkość ruchu, poziom proaktywności

- **Użytkownik 1:** osoba starsza z trudnościami w chodzeniu; oczekuje wolnego robota i wyraźnych sygnałów
- **Użytkownik 2:** pracownik biura; oczekuje robota który nie przeszkadza i nie blokuje drogi
- **Użytkownik 3:** dziecko; robot powinien być bardziej ostrożny i używać prostszych komunikatów

Cel: minimalizacja zakłóceń i maksymalizacja poczucia komfortu konkretnej osoby, nie średniej użytkowników

Metody: profil explicit (preferencje podane przez użytkownika) + profil implicit (wnioskowany z zachowania)

Profil użytkownika - składowe i źródła

Cechy stale (explicit)

- Wiek i mobilność (poruszanie się z laseczką, na wółku)
- Preferencje kulturowe (kraj pochodzenia, język)
- Znane fobie lub lęki (np. lęki przed maszynami)
- Preferowany styl komunikacji (werbalny / niewerbalny)
- Historia interakcji z robotami (nowicjusz / doświadczony)
- Rola w organizacji (pacjent, personel, gość)

Cechy dynamiczne (implicit)

- Aktualny stan emocjonalny (ekspresja twarzy, tempo mowy)
- Poziom spieszczenia (prędkość chodzenia, gęstość kontaktu)
- Odpowiedzi na poprzednie zachowania robota (wycofanie, kiwnięcie)
- Zajętość (słucha muzyki, rozmawia przez telefon)
- Pozycja i orientacja ciała względem robota
- Historia dzisiejszej sesji (akceptacje, odrzucenia propozycji)

Uczenie preferencji użytkownika w czasie rzeczywistym

- **Cel:** robot aktywnie aktualizuje model preferencji na podstawie sygnału zwrotnego użytkownika
- **Sygnały zwrotne:** wycofanie się (zbyt blisko), kiwnięcie (OK), komenda słowa (szybciej / wolniej), styl chodzenia
- **Regresja Bayesowska:** model dystansu preferowanego $d^* \sim N(\mu, \sigma^2)$; aktualizacja μ i σ po każdej obserwacji
- **Inverse RL (IRL):** z obserwacji ludzkich zachowań wnioskuj funkcję nagrody; zastosuj do polityki robota
- **Gaussian Process Regression:** interpolacja preferencji dystansu dla różnych kontekstów (korytarz, winda, sala)
- **Prywatność:** dane profilowe przechowywane lokalnie; opcja reset profilu przez użytkownika w dowolnej chwili
- **Cold start:** nowy użytkownik startuje z domyślnymi parametrami kulturowymi; personalizacja po ~5 minutach interakcji

Bayesowska aktualizacja preferencji dystansu (online)

```
import numpy as np

class DistancePreferenceModel:
    """Gaussowski prior nad preferowanym dystansem d* [m]."""
    def __init__(self, mu0=1.2, sigma0=0.4):
        self.mu = mu0 # wartosc oczekiwana poczatkowa
        self.sigma = sigma0 # odchylenie standardowe (niepewnosc)
        self.obs_sigma = 0.15 # szum pomiaru (gestosc obserwacji)

    def update(self, observed_distance: float, feedback: str):
        """Aktualizacja po obserwacji; feedback: "ok"/"too_close"/"too_far"."""
        if feedback == 'too_close':
            z = observed_distance + 0.3 # uzytkownik chce wiekszy dystans
        elif feedback == 'too_far':
            z = observed_distance - 0.2 # uzytkownik akceptuje mniejszy
        else:
            z = observed_distance # OK - to jest d*
        # Kalman update: posterior Gaussian
        K = self.sigma**2 / (self.sigma**2 + self.obs_sigma**2)
        self.mu += K * (z - self.mu)
        self.sigma = np.sqrt((1 - K) * self.sigma**2)
        return self.mu, self.sigma
```

Opis: Po 5–10 interakcjach sigma spada do $\sim 0,05$ m; mu zbiezna do prawdziwej preferencji uzytkownika.

Komunikacja robota z człowiekiem - kanały

Mowa (TTS)

Synteza mowy: przyjazny głos, odpowiednia głośność. Robot informuje o zamiarach: 'Przechodzę po lewej stronie'

Światła LED

Kolory sygnalizują stan: zielony = gotowy, żółty = zatrzymanie, czerwony = ostrzeżenie, niebieski = naładowanie

Gestykulacja

Ramię wskazuje kierunek lub zaprasza; kiwnięcie głowy potwierdza. Wymaga platformy z ramionami

Wyswietlacz twarzy

Animowane oczy lub emotikonki: przekazują stan emocjonalny (zdziwienie, zaproszenie, przepraszam)

Ruch anticipacyjny

Robot zaczyna skrecać wcześniej niż wymagane, sygnalizując zamiar. Badania: anticipatory motion zmniejsza konflikty o 40%

Personalizacja głosu

Ton, tempo i język dopasowane do profilu użytkownika. Dziecko: wolniej, prostsze słowa. Senior: większe natężenie

Pipeline personalizacji HRI - od kontaktu do adaptacji

1

Identyfikacja użytkownika

Rozpoznawanie twarzy /
tokenu RFID / konta;
ładowanie lub tworzenie
profilu użytkownika

2

Ocena kontekstu

Środowisko (szpital/biuro),
godzina dnia, tłok; wybór
bazowej polityki nawigacyjnej

3

Inicjacja interakcji

Kontakt wzrokowy, kiwnięc
lub głos; robot sygnalizuje
gotowość do interakcji
i zamiar ruchu

4

Wykonanie z monitoringiem

Nawigacja z aktywna
obserwacja sygnalizacji
zwrotnej; rejestracja
odległości, reakcji ciała, słów

Ewaluacja nawigacji społecznej: metryki i benchmarki

- **Intrusion into Personal Space (IPS):** procent czasu, gdy robot narusza strefe osobista ($< 1,2$ m) bez zaproszenia
- **Path Irregularity (PI):** odchylenie trasy robota od trajektorii bez pieszych; wskaźnik zakłocen w nawigacji
- **Social Space Violation (SSV):** liczba wejść w O-space grupy lub strefe konwersacji
- **Time-to-pass (TTP):** czas potrzebny robotowi do minięcia pieszego; im krótszy tym mniej ograniczeń
- **Perceived Safety Rating (PSR):** subiektywna ocena bezpieczeństwa przez pieszych (kwestionariusz Likerta)
- **Comfort Score (CS):** średnio oceniana wygoda interakcji; zbierany przez aplikacje mobilną lub kiosk
- **Benchmarki:** SocNav1/2 (Manso et al.), SEAN-EP (Tsoi et al.), CrowdNav (Chen et al.); porównywalne wyniki

Klasyfikator profilu użytkownika i adaptacja parametrów

```
import numpy as np

PROFILE_PARAMS = {
    'senior': {'v_max': 0.4, 'dist_safe': 1.5, 'tts_speed': 0.8},
    'child':  {'v_max': 0.5, 'dist_safe': 1.8, 'tts_speed': 0.9},
    'adult':  {'v_max': 0.8, 'dist_safe': 1.2, 'tts_speed': 1.0},
    'worker': {'v_max': 1.0, 'dist_safe': 1.0, 'tts_speed': 1.1},
}

def classify_user(face_age: float, walking_speed: float,
                 uses_aid: bool) -> str:
    """Prosty klasyfikator profilu użytkownika."""
    if uses_aid or face_age > 65:
        return 'senior'
    if face_age < 14:
        return 'child'
    if walking_speed > 1.2:
        return 'worker'
    return 'adult'

def get_nav_params(profile: str, pref_model) -> dict:
    base = PROFILE_PARAMS[profile].copy()
    # Nadpisz dystans z modelu Bayesowskiego (z Kodu 3)
    base['dist_safe'] = pref_model.mu
    return base
```

Opis: Klasyfikacja wstępna z szybkich cech; model Bayesowski (Kod 3) następnie personalizuje dist_safe online.

Studium przypadku: robot w szpitalu wielokulturowym

- Platforma: robot usługowy na korytarzach szpitalnych; personel z 12 krajów, pacjenci różnych kultur i grup wiekowych
- System detekcji: YOLO dla pieszych + MediaPipe Pose dla orientacji + gaze estimation dla kontaktu wzrokowego
- Profil domyślny: strefa 1,5 m, prędkość max 0,5 m/s, komunikacja głosowa po polsku lub angielsku
- Adaptacja kulturowa: detekcja języka (ASR) uaktywnia moduł proksemiki (+20% dystansu dla kultur nordyckich)
- Adaptacja do seniora: twarz + laska / wózek -> tryb senior: $v_{\text{max}} = 0,4$ m/s, dystans 1,8 m, głos wolniejszy
- Adaptacja do dziecka: wiek < 14 z rozpoznania twarzy -> tryb dziecko: jeszcze większy dystans, komunikacja prostsza
- Wyniki: IPS zredukowane o 62% względem klasycznej nawigacji, PSR wzrost o 1,8 pkt (skala 1–7), TTP o 8% dłuższy

Wyzwania i kierunki badan w nawigacji społecznej

Wyzwania techniczne i społeczne

- Niezawodność detekcji emocji i gestów w różnych warunkach oświetlenia i kątach widzenia
- Translacja norm kulturowych na parametry numeryczne bez stereotypizacji
- Zimny start nowego użytkownika: brak danych historycznych utrudnia personalizację
- Konflikty norm: jedna osoba prosi o szybszy ruch, druga w tej samej chwili o zwolnienie
- Prywatność: biometryczna identyfikacja użytkownika wymaga zgody i zasad RODO
- Obliczenia w czasie rzeczywistym: wielowartościowa mapa kosztów społecznych musi być odświeżana < 100 ms

Kierunki badan (2024-2026)

- Foundation models dla HRI: VLM jako zrozumiały interpreter sygnałów społecznych
- Uczenie przez demonstrację: robot uczy się norm z filmów zachowań pieszych bez ręcznie zdefiniowanych reguł
- Teorie umysłu (ToM): robot wnioskuje o intencjach i stanach psychicznych ludzi z obserwacji
- Swoi tłum vs obcy tłum: wielorobotowe systemy społecznej nawigacji z konsensem norm grupowych
- Ewaluacja długookresowa: badania wielomiesięczne w szpitalach i biurach; mierzenie zaufania w czasie

PODSUMOWANIE

01

Social Force Model i ORCA dają deterministyczne podstawy unikania tłumu; modele danych (Transformer) przewidują intencje.

02

Proksemika Halla definiuje strefy, które robot musi szanować; naruszenie strefy osobistej niszczy zaufanie użytkowników.

03

Normy kulturowe istotnie różnią się w skali globalnej; robot działający w wielu krajach wymaga modułu adaptacji kontekstu kulturowego.

04

Personalizacja HRI opiera się na profilu użytkownika, uczeniu online preferencji i wielokanalowej komunikacji niewerbalnej.

05

Ewaluacja nawigacji społecznej wymaga metryk jakości HRI (ITT, PSR, PFC) obok klasycznych wskaźników nawigacji (RMSE, sukces).

Zadanie projektowe i pytania problemowe

- Dlaczego SFM może generować oscylacje w wąskim korytarzu? Zaproponuj modyfikacje parametrów lub dodatkowe ograniczenie, które usunie ten problem.
- Robot wchodzi między dwie osoby rozmawiające (O-space). Jakie sygnały zachowania powinny temu zapobiec i jak je zakodować w mapie kosztów?
- Użytkownik z Japonii oczekuje dystansu 1,5 m, a użytkownik z Brazylii 0,7 m. Jak w jednym systemie obsługiwać obie preferencje bez ręcznie wprowadzonych warunków?
- Zadanie: zaimplementuj klasę SocialCostmap z anizotropowym Gaussem (Kod 2) i przetestuj ją na symulowanej scenie z 5 pieszymi poruszającymi się w różnych kierunkach. Wizualizuj wynikową mapę kosztów i sprawdź, że planista A* omija ludzi z boku, nie z przodu.
- Bonus: zintegruj DistancePreferenceModel (Kod 3) z Nav2 jako dynamiczny mnożnik strefy inflacji i pokaz zbieżność preferencji dla 3 różnych profili użytkowników w symulacji.